



QUÉT MÃ XEM MÃ NGUỒN & DEMO

1. GIỚI THIỆU BÀI TOÁN & ĐỘNG LỰC NGHIÊN CỨU

Bài toán VRPTW (Vehicle Routing Problem with Time Windows): Xác định tập hợp lộ trình tối ưu cho đội xe đồng nhất xuất phát từ kho trung tâm phục vụ tập khách hàng rải rác địa lý, thỏa mãn tải trọng xe Q và phục vụ trong khung thời gian bắt buộc $[e_i, l_i]$.

Hàm mục tiêu từ điển (Lexicographic):

$$\min f(s) = M \cdot N_V(s) + D_T(s), \quad \text{với } M = 10^5 \gg \max D_T$$

(Ưu tiên tối thượng giảm số xe vận hành N_V , sau đó giảm quãng đường D_T)


- Hạn chế ALNS truyền thống:** Chọn toán tử ngẫu nhiên qua bánh xe Roulette tĩnh, thiếu cơ chế cảm nhận bế tắc, dễ sa lầy tại các cực tiểu địa phương sâu.
- Hạn chế End-to-End DRL:** Các mô hình nơ-ron thuần túy dễ vi phạm khung thời gian và bùng nổ nghiệm không khả thi khi mở rộng quy mô đồ thị.
- Đột phá để xuất:** Hệ thống lai 3 tầng DDQN-ALNS kết hợp điều khiển phân cấp (Macro/Micro), lọc cạnh bằng Contrastive GNN và tối ưu toàn cục qua Set Partitioning MILP.

2. TẬP DỮ LIỆU & THIẾT LẬP THỰC NGHIỆM

Bộ Thực Nghiệm	Số Bài	Quy Mô	Đặc Trưng Không – Thời Gian
Solomon-100	56	100 khách	6 họ bài toán: Cụm (C1, C2), Ngẫu nhiên (R1, R2), Hỗn hợp (RC1, RC2)
Homberger-200	60	200 khách	10 bài toán x 6 họ cấu trúc địa hình không gian phức tạp
Homberger-400	60	400 khách	Quy mô lớn thử thách cực hạn năng lực tìm kiếm và tránh dừng sớm

- Quy chuẩn Cold-Start độc lập:** Toàn bộ bộ nhớ đệm (EliteArchive) được làm sạch hoàn toàn giữa các lượt chạy. Mọi bộ giải bắt đầu độc lập từ nghiệm tham lam ban đầu (100% tái lập khoa học, zero rò rỉ nghiệm).
- Domain Randomization (DR):** Huấn luyện mô hình DRL duy nhất trên đồ thị tự sinh quy mô nhỏ $N \in [20, 100]$, đồng bộ tham số θ^* và chuyển giao trực tiếp Zero-Shot sang toàn bộ 176 bài toán chuẩn mà không cần fine-tuning.
- Môi trường thực nghiệm:** Triển khai trên Python 3.10, PyTorch 2.1, HiGHS MILP C++ Solver, biên dịch JIT qua Numba; thực thi trên phần cứng Apple Silicon M1 (8 nhân, 16GB RAM) và Linux HPC.

3. PHƯƠNG PHÁP THỰC HIỆN: KIẾN TRÚC LAI PHÂN CẤP HYBRID DDQN – ALNS



Tầng 1: Macro Plateau Controller (π_{macro})

SEMI-MDP • 13D

Mạng Dueling DDQN nhận vector trạng thái 13 chiều đặc trưng (độ bế tắc, áp lực tải, nhiệt độ). Cứ sau $\Delta_{\text{seg}} = 100$ bước, mô hình chuyển đổi linh hoạt giữa **7 chế độ chiến lược** (Default, Intensify, Diversify, TW-Rescue, Pool-Recombine, Route-Reduce, Infeasible-Descent) để chủ động phá vỡ các tiểu địa phương.

Tầng 2: Micro Selection & LAC (π_{micro})

65 ACTION PAIRS • 20D

Mạng DDQN thứ hai điều hành 65 cặp toán tử (13 Phá huỷ $\times$ 5 Sửa chữa) dựa trên vector 20D và cơ chế tập trung Entropy-Softmax. Tích hợp mạng **Learned Acceptance (LAC)** với MLP Lookahead $H=80$ bước, thay thế hoàn toàn Simulated Annealing cổ điển.

Tầng 3: Contrastive GNN Edge Pruning

-98.74% SEARCH EDGES

Mô hình Graph Neural Network 3 lớp huấn luyện qua hàm mất mát tương phản InfoNCE + BCE. Mô hình lọc sạch **98.74% các cạnh kém hứa hẹn** trong đồ thị không gian-thời gian, giảm độ phức tạp từ $O(N^2)$ xuống $O(kN)$, giúp tăng tốc ALNS gấp 4 lần.



Tầng 4: Set Partitioning Recombination

HiGHS MILP SOLVER

Tích lũy các tuyến tốt nhất vào **Dual-Slot Route Archive** (75% lộ trình tinh hoa + 25% lộ trình đa dạng). Định kỳ kích hoạt solver HiGHS giải bài toán quy hoạch nguyên Set Partitioning trong giới hạn 4.0s để lấp ghép nghiệm tối ưu toàn cục, tiệm cận kỷ lục thế giới BKS.

4. KẾT QUẢ THỰC NGHIỆM & PHÂN TÍCH ĐỐI CHUẨN QUỐC TẾ

Tập Dữ Liệu	Thuật Toán	Số Xe TB (N_V) ↓	Quãng Đường TB (D_T) ↓	Thời Gian (s)	Ý Nghĩa Thống Kê (Wilcoxon)
Solomon-100 (56 bài toán)	BKS (Kỳ lục thế giới)	7.07	1013.36	—	—
	ALNS-Base	7.54	1017.31	10.1s	Baseline
	Hybrid-DDQN (Đề xuất)	7.34*	1017.82	39.0s	$p = 0.00127$ (Thắng vượt trội)
Homberger-200 (60 bài toán)	ALNS-Base	11.87	3009.91	3.9s	Baseline
	Hybrid-DDQN (Đề xuất)	11.58*	2844.73* (-165.18 km)	35.8s	$p = 1.34 \times 10^{-9}$ (Đột phá thống kê)



- 100% Bảo Toàn Tính Khả Thi:** Không ghi nhận bất kỳ vi phạm khung giờ hay tải trọng nào trên toàn bộ 580 lượt chạy độc lập (176 bài toán $\times$ 5 seeds).
- Ưu thế Quãng đường tại Quy mô 200:** Khi khớp số lượng xe sẵn, Hybrid-DDQN giảm tổng quãng đường di chuyển từ **1.75% đến 4.07%** (tiết kiệm trung bình 165.18 km, $p = 1.34 \times 10^{-9}$).
- Khắc phục Lạm phát Xe của Google OR-Tools:** Trên họ RC2, OR-Tools lạm phát tới 6.50 xe (+80%), trong khi Hybrid-DDQN duy trì đúng mức sản 3.25 xe, tối ưu chi phí vận hành đội xe thực tế.

5. KẾT LUẬN & ĐÓNG GÓP KHOA HỌC

- Đóng góp Lý thuyết:** Thiết lập khung tối ưu lai Trí-Level đầu tiên cho VRPTW, hài hòa năng lực điều hướng của Deep RL, tốc độ tia cạnh của GNN và độ chính xác toàn cục của MILP.
- Khả năng Tổng quát hóa Zero-Shot:** Chiến lược Domain Randomization chứng minh mô hình huấn luyện trên đồ thị nhỏ $N \in [20, 100]$ có thể chuyển giao trực tiếp sang đồ thị 400 khách mà không cần fine-tuning.
- Minh bạch Thực nghiệm & Tái lập:** Tuân thủ nghiêm ngặt quy chuẩn Independent Cold-Start, công bố toàn bộ log nghiệm và mã nguồn đối chuẩn tin cậy cho cộng đồng vận trù học.
- Hướng Mở Rộng Đầy Hứa Hẹn:** Mở rộng khung lai cho đội xe không đồng nhất (Heterogeneous Fleet) và bài toán xe tải điện kết hợp trạm sạc pin (EVRPTW).

-165.18 km

Quãng đường tiết kiệm TB (Homberger-200)

Wilcoxon $p = 1.34 \times 10^{-9}$ (Đột phá)

-98.74%

Cắt tia không gian tìm kiếm cạnh

Contrastive GNN • $O(N^2) \rightarrow O(kN)$

100%

Bảo toàn tính khả thi vận hành

Zero vi phạm tải & khung giờ (580 runs)

Zero-Shot

Tổng quát hóa quy mô đồ thị

Huấn luyện $N=100 \rightarrow$ Suy luận $N=400$

• ỨNG DỤNG THỰC TIỄN: NAMI DISPATCH PORTAL

Thuật toán Hybrid DDQN-ALNS đã được đóng gói thành microservice API trên nền tảng NAMI Dispatch Portal, hỗ trợ tái tối ưu lộ trình tức thời ($< 5s$) khi phát sinh đơn hàng khẩn cấp hoặc biến động giao thông thực tế trong chuỗi cung ứng.

Tài liệu tham khảo chọn lọc:

- [1] S. Ropke & D. Pisinger, "An Adaptive Large Neighborhood Search Heuristic for the VRPTW", *Transportation Science*, 40(4), pp. 455–472, 2006.
- [2] V. Minh et al., "Human-level control through deep reinforcement learning", *Nature*, vol. 518, pp. 529–533, 2015.
- [3] H. Gehring & J. Homberger, "A Parallel Two-phase Metaheuristic for Routing Problems", *APIOR*, vol. 18, pp. 35–47, 2001.